

Segunda entrega Modelos Estadísticos para la Clasificación y Regresión

El objetivo de esta tarea es entrenar y comparar distintos modelos de regresión sobre datos sintéticos, y analizar cómo se comportan las predicciones cuando los datos provienen de una distribución ligeramente diferente.

El conjunto de datos sobre el que realizaremos las predicciones estará formado por dos subconjuntos. El primero proviene de la misma distribución que los datos de entrenamiento, mientras que el segundo será similar, pero se generará sumando una constante, generada de manera aleatoria, a todas las variables, lo que modificará ligeramente su distribución. Debido a esta diferencia, esperamos que el modelo obtenga errores pequeños al predecir sobre el primer subconjunto y errores más grandes sobre el segundo. En un caso real, no sabríamos que un conjunto fue generado a partir del otro ni que existe este desplazamiento en los datos. Por ello, una buena estrategia para detectar y entender este tipo de comportamientos es aplicar un Análisis de Componentes Principales (PCA), que permite visualizar las relaciones y diferencias entre ambos subconjuntos en el espacio de las variables.

- 1) Generar un conjunto de datos sintético con 150 observaciones y 50 variables ($X_1, X_2, \dots, X_{50}$). Las variables deben tener correlaciones no nulas entre sí. Para lograrlo, utilizar una matriz de correlaciones (provista en el EVA) y generar los datos con una distribución normal multivariada.
- 2) Definir una variable objetivo Y como combinación lineal de las 50 variables, donde solo 5 serán informativas (tendrán coeficientes no nulos). Agregar un pequeño ruido aleatorio gaussiano con media cero y poca varianza (por ejemplo, 0.25).
- 3) Separar los datos en:
 - Conjunto de entrenamiento: 100 observaciones
 - Conjunto de test: 50 observaciones
- 4) Entrenar tres modelos distintos utilizando el conjunto de entrenamiento: Regresión lineal simple, Regresión Ridge y Regresión Bayesiana. Graficar los coeficientes (pesos) estimados para cada una de las 50 variables (como en el laboratorio 4). Comparar los resultados y comentar respecto a las variables que sabemos que contienen información. Elegir uno de los modelos para continuar, justificando la elección.
- 5) Aplicar un análisis de componentes principales (PCA) al conjunto de entrenamiento. Graficar las dos primeras componentes principales (PC1 y PC2) para visualizar la estructura de los datos.
- 6) Dividir el conjunto de test en dos subconjuntos iguales:
 - A: 25 observaciones
 - B: 25 observaciones

Generar un vector aleatorio de tamaño 50 (por ejemplo, con valores uniformes entre -10 y 10) y sumarlo a todas las filas del conjunto A. De esta manera, el conjunto A representará datos provenientes de una distribución desplazada, mientras que B mantendrá la distribución original.

- 7) Usar el modelo elegido en la parte 2 para predecir sobre ambos conjuntos (A modificado y B). Calcular el error de predicción en cada observación. Comentar los resultados.
- 8) Proyectar los conjuntos A y B en el espacio de las componentes principales obtenidas en la parte 3 y graficar las proyecciones (PC1 vs PC2), coloreando los puntos según el error de predicción. Comentar los resultados.
- 9) Si no conociera las constantes que se le sumaron a las variables del conjunto A, ¿qué estrategia elegiría para mejorar las predicciones en ese conjunto?